Introducción

Un proyecto de ETL se define como *Extract, Transform* y *Load* (o extracción, transformación y carga en spañol) y a continuación expondremos paso a paso este proceso dividido en 3 partes, con 5 transformaciones en total.

Parte 1: Extracción

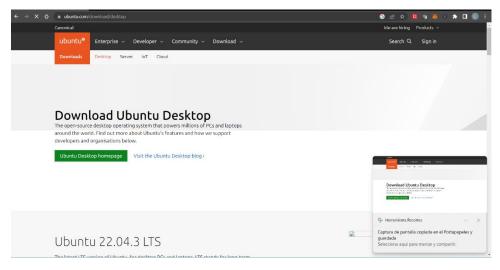
1.1 Creación de Máquina Virtual con Ubuntu

1.1.1 En primer lugar, descargamos e instalamos VirtualBox desde el sitio web oficial en https://www.virtualbox.org/ para poder crear una Máquina Virtual (VM). En este caso se muestra la descarga para sistema operativo Windows.



Ilustración 1. Descarga de VirtualBox para Windows. Captura de pantalla desde https://www.virtualbox.org/

1.1.2 Una vez descargada e instalada la máquina virtual, procedemos a descargar Ubuntu Desktop en su versión 22.04.3 LTS.



- 1.1.3 Luego de descargar Ubuntu, en el Oracle Virtual Machine, hacemos:
 - Click a "New", ponemos "Ubuntu" como el nombre;
 - Confirmamos que estamos de acuerdo con el folder donde va a ser creada;
 - Seleccionamos la ISO image buscando la versión de Ubuntu que descargamos
 - Hacemos click en "Next"

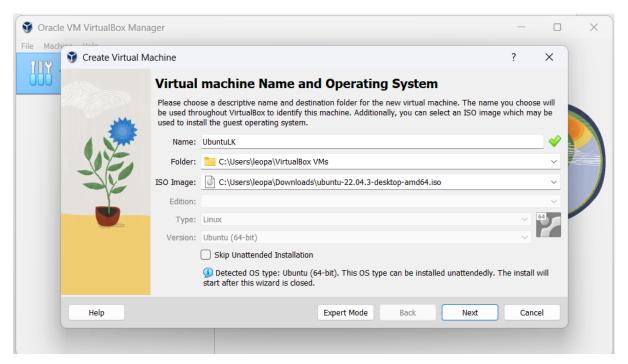


Ilustración 3. Creación de una nueva máquina virtual. Captura de pantalla desde Oracle VM VirtualBox®

1.1.3. Para este caso en particular, seleccionamos 2 GB de RAM y en procesadores le asignamos 2 CPUs. Para disco duro, asignamos 25 GB de espacio, dejando habilitada la opción de preasignar todo el tamaño del disco duro.

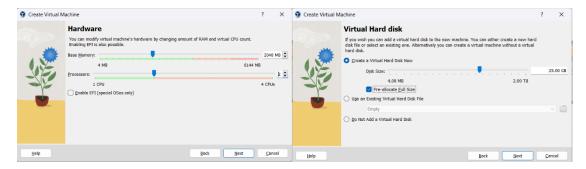


Ilustración 4. Creación de atributos de la nueva máquina virtual creada. Captura de pantalla desde Oracle VM VirtualBox®

1.2 Instalación de Python en Ubuntu

1.2.1 Una vez instalado Ubuntu en la Virtual Machine, procedemos a abrir la terminal de comandos y actualizamos la lista de paquetes disponibles en los repositorios configurados del sistema. Luego invocamos el software que se requiere para instalar Python en su versión actual. Actualizamos también a los lanzamientos de repositorios más recientes, y volvemos a actualizar.

- \$ sudo apt update
- \$ sudo apt-get install software-properties-common
- \$ sudo add-apt-repository ppa:deadsnakes/ppa
- \$ sudo apt update

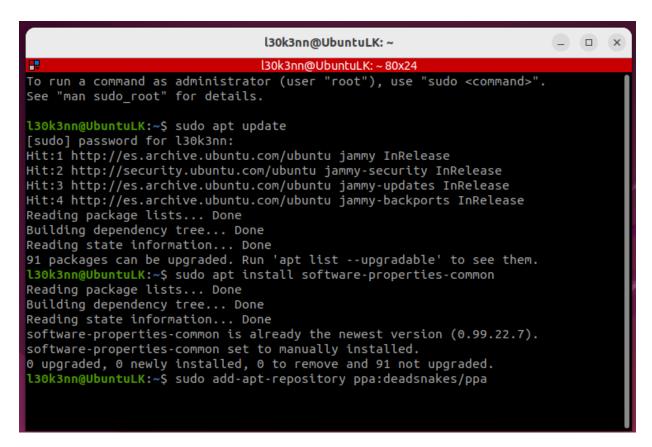


Ilustración 4. Parte I: Instalación de Python en Ubuntu por medio de la Terminal de comandos. Screenshot de Ubuntu.

1.2.2. Una vez actualizado, procedemos a instalar Python y posteriormente a verificar la versión instalada, en este caso instalamos la versión 3.10.12.

\$ sudo apt-get install python3.8 \$ python3 –version

```
l30k3nn@UbuntuLK: ~
                                                                                _ _ X
Adding key to /etc/apt/trusted.gpg.d/deadsnakes-ubuntu-ppa.gpg with fingerprint
F23C5A6CF475977595C89F51BA6932366A755776
Hit:1 http://es.archive.ubuntu.com/ubuntu jammy InRelease
Hit:2 http://es.archive.ubuntu.com/ubuntu jammy-updates InRelease
Hit:3 http://es.archive.ubuntu.com/ubuntu jammy-backports InRelease
Get:4 https://ppa.launchpadcontent.net/deadsnakes/ppa/ubuntu jammy InRelease [18
,1 kB]
Get:5 https://ppa.launchpadcontent.net/deadsnakes/ppa/ubuntu jammy/main amd64 Packages [23,4 kB]
Get:6 https://ppa.launchpadcontent.net/deadsnakes/ppa/ubuntu jammy/main i386 Pac
kages [9 996 B]
Get:7 https://ppa.launchpadcontent.net/deadsnakes/ppa/ubuntu jammy/main Translat
ion-en [4 800 B]
Hit:8 http://security.ubuntu.com/ubuntu jammy-security InRelease
Fetched 56,2 kB in 4s (14,5 kB/s)
Reading package lists... Done
l30k3nn@UbuntuLK:~$ sudo apt-get update
Hit:1 http://security.ubuntu.com/ubuntu jammy-security InRelease
Hit:2 http://es.archive.ubuntu.com/ubuntu jammy InRelease
Hit:3 https://ppa.launchpadcontent.net/deadsnakes/ppa/ubuntu jammy InRelease
Hit:4 http://es.archive.ubuntu.com/ubuntu jammy-updates InRelease
Hit:5 http://es.archive.ubuntu.com/ubuntu jammy-backports InRelease
Reading package lists... Done
l30k3nn@UbuntuLK:~$ sudo apt-get install python3.8
```

Ilustración 5. Parte II: Instalación de Python en Ubuntu por medio de la Terminal de comandos. Screenshot de Ubuntu.

1.3. Instalación de paquetería para Python

1.3.1 Ahora instalamos Python y el gestor de paquetería:

\$python3
Instalación
\$apt update
\$sudo apt update
\$sudo apt -y upgrade
Para verificar Instalación de Python
\$python3 -V
Instalación de gestor de paquetes de dependencias
\$sudo apt install -y python3-pip
Para verificar Instalación del gestor
\$pip3 -V
Instalacion de dependencias en entorno profesional
\$apt install -y build-essential libssl-dev libffi-dev python3-dev

```
ountuLK:~$ sudo apt install ipython3
 sudo] password for l30k3nn:
Sorry, try again.
[sudo] password for l30k3nn:
Reading package lists... Done
Building dependency tree... Done
Reading state information... Done
ipython3 is already the newest version (7.31.1-1).
0 upgraded, 0 newly installed, 0 to remove and 30 not upgraded.
l30k3nn@UbuntuLK:~$ sudo apt-get install python3-setuptools
Reading package lists... Done
Building dependency tree... Done
Reading state information... Done
python3-setuptools is already the newest version (59.6.0-1.2ubuntu0.22.04.1).
oʻupgraded, o newly installed, o to remove and 3o`not upgraded.
l30k3nn@UbuntuLK:~$ sudo add-apt-repository universe
Adding component(s) 'universe' to all repositories.
 Press [ENTER] to continue or Ctrl-c to cancel.
Hit:1 http://es.archive.ubuntu.com/ubuntu jammy InRelease
Get:2 http://es.archive.ubuntu.com/ubuntu jammy-updates InRelease [119 kB]
Get:3 http://security.ubuntu.com/ubuntu jammy-security InRelease [110 kB]
Hit:4 https://ppa.launchpadcontent.net/deadsnakes/ppa/ubuntu jammy InRelease
Get:5 http://es.archive.ubuntu.com/ubuntu jammy-backports InRelease [109 kB]
Get:6 http://es.archive.ubuntu.com/ubuntu jammy-updates/main amd64 DEP-11 Metadata [101 kB]
Get:7 http://es.archive.ubuntu.com/ubuntu jammy-updates/universe amd64 DEP-11 Metadata [305 kB]
Get:8 http://es.archive.ubuntu.com/ubuntu jammy-updates/multiverse amd64 DEP-11 Metadata [940 B]
Get:9 http://security.ubuntu.com/ubuntu jammy-security/main amd64 DEP-11 Metadata [43,0 kB]
Get:10 http://security.ubuntu.com/ubuntu jammy-security/universe amd64 DEP-11 Metadata [55,2 kB]
Get:11 http://es.archive.ubuntu.com/ubuntu jammy-backports/main amd64 DEP-11 Metadata [4 932 B]
Get:12 http://es.archive.ubuntu.com/ubuntu jammy-backports/universe amd64 DEP-11 Metadata [18,8 kB]
Fetched 866 kB in 3s (272 kB/s)
Reading package lists... Done
l30k3nn@UbuntuLK:~$ sudo apt-get install python3-pip
Reading package lists... Done
Building dependency tree... Done
Reading state information... Done
python3-pip is already the newest version (22.0.2+dfsg-1ubuntu0.3).
0 upgraded, 0 newly <u>i</u>nstalled, 0 to remove and 30 not upgraded.
```

Ilustración 6. Parte II: Instalación de paquetería para Python en Ubuntu por medio de la Terminal de comandos. Screenshot de Ubuntu.

Parte 2: Transformación

- 2.1. Creamos un nuevo archivo Python, lo llamamos "codlfraestructuras.py", y en nuestra Virtual Machine abrimos un IDE (en nuestro caso VSCode).
- 2.2.1 Abrimos el archivo "codlfraestructuras.py" e importamos las siguientes librerías:
 - "requests" (se utiliza para realizar solicitudes HTTP y obtener datos desde una URL externa)
 - "statistics" (se utiliza para realizar operaciones estadísticas, como calcular la media o la moda)
 - "mysql.connector" (se utiliza para interactuar con bases de datos MySQL, estableciendo conexiones y creando cursores)
- 2.2.2 Usamos la función "requests.get" para obtener datos de una URL que genera usuarios aleatorios. El parámetro "results=100" limita el número de datos que recibimos a 100.

```
#Se importa la libreria que se van a utilizar en el proyecto
import requests
import mysql.connector
import statistics

#Por medio de este comando se hace el llamado de los datos de la URL
#El igual despues de la URL sirve para limitar el número de datos
url = requests.get('https://randomuser.me/api?results=100')

#Convierte la información de la URL en un formato typo JSON
informacion = url.json()

#Hace el llamado a las claves del diccionario
informacion.keys()

#Creamos una variable con los datos que estan en la llave 'results'
resultados = informacion['results']
```

2.3. Transformación I

La primera transformación consiste en encontrar la edad más frecuente en la que los usuarios se registraron. Para ello, extraemos sus edades actuales y el tiempo que llevan registrados. Luego calculamos la diferencia entre estas para obtener nuestra respuesta, y proporcionamos *insights* sobre estas (como la edad media, moda, máxima y mínima).

A continuación presentamos una forma de extraer el porcentaje de usuarios en cada rango de edad, clasificados en las categorías de edades [0-20], [21-40], [41-60], y [61+]. El formato del resultado debe seguir el patrón de "El X% de usuarios se registraron a una edad menor de X años."

```
def rango_etario(listValores =[]):
    longitud = len(listValores)
    edades = {'0-20':0,'21-40':0,'41-60':0, '61+':0} #Guarda los rangos de edades
    for edad in listValores: #Para cada edad
        if edad < 21: #Si es menor que 21
             edades['0-20'] = edades['0-20'] + 1 #Agrego el elemento a esta llave
         if (edad >= 21 and edad < 41)==True:
             edades['21-40'] = edades['21-40'] + 1 #Agrego el elemento a esta llave
         if (edad > 40 and edad < 61)==True:
             edades['41-60'] = edades['41-60']+ 1 #Agrego el elemento a esta llave
         if edad > 60:
             edades['61+'] = edades['61+'] + 1 #Agrego el elemento a esta llave
    resultEdad1 = (edades['0-20']/longitud*100) #Valor de la Key '0-20' resultEdad2 = (edades['21-40']/longitud*100) #Valor de la Key '21-40' resultEdad3 = (edades['41-60']/longitud*100) #Valor de la Key '41-60'
    resultEdad4 = (edades['61+']/longitud*100) #Valor de la Key
    return(resultEdad1,resultEdad2,resultEdad3,resultEdad4) #Retorna los valores a una lista
rango etario(edad registro)
```

2.4. Transformación II

En la segunda transformación nos centramos en buscar el país con el mayor número de usuarios definiendo la función "numUsuarios". Para ello, realizamos un análisis para encontrar la moda, o el país más frecuente en las listas de "location y "country". Nuestra función devuelve el nombre del país y la cantidad de usuarios que tienen en ese país. Esto podría ser de interés si se quiere averiguar cuál es el país con mayor número de usuarios en la plataforma. El formato del resultado debe seguir el patrón de "El país en donde se encuentra el mayor número de usuarios es: X con X personas."

```
#Nuestra de informacion 2
#Pais con el mayor número de usuarios

pais = informacion['results'][2]['location']['country'] #Realiza una busqueda del pais

def numUsuarios(): #Función para hallar el pais con mayor número de usuarios

vModaUsuPais = 0 #Se le asigna a la variable 0

paises =[] #Se crea una lista de paises

for i in range(len(informacion['results'])): #Itera en el rango de la lista

paises.append(informacion['results'])]: #Itera en el rango de la lista

modaPais = statistics.mode(paises) #Se halla la moda en la lista paises

for i in range(len(paises)): #Itera en en la longitud de la lista paises

for i in range(len(paises)): #Itera en en la longitud de la lista dada (paises)

if paises[i] == modaPais: #La condición saca el nombre del país que sea igual a la moda

vModaUsuPais = vModaUsuPais + 1 #Reasigna la variable de la moda de los usuarios por país

return(modaPais,vModaUsuPais) #Retorna los valores a una lista

numUsuarios() #Se hace el llamado de la función
```

2.5. Transformación III

El tercer análisis consiste en evaluar el grado de seguridad de la contraseña de cada usuario, utilizando funciones para examinar la complejidad de las contraseñas y clasificarlas en tres grados según los siguientes criterios:

- una seguridad de grado 1 incluye 2 caracteres repetidos
- una de grado 2 tiene solo letras o solo números
- una de grado 3 tiene una combinación de tanto letras como números

Las funciones "separar_letras" y "separar_ltrs_num" se encargan de contar las repeticiones de letras y números, respectivamente. La función "grado seguridad"

determina el grado de seguridad según nuestros criterios, y la función "seguridad" calcula y nos muestra el porcentaje de contraseñas en cada grado.

El formato del resultado debe seguir el patrón de "La contraseña de grado 1 representan un X%, las de grado 2 representan un X% y las de grado 3 un X%."

2.6. Transformación IV

La cuarta transformación analiza la distribución de la zona horaria de los usuarios. Utilizando la función "zona_horaria" recopilamos información sobre las diferencias de usos horarios de cada persona e identificamos la zona horaria más común (junto con el número de personas en esa zona).

El formato de los resultados debe seguir el patrón de "la mayor zona horaria se encuentra entre las X con X usuarios" y mostrar la lista.

2.7. Transformación V

Aquí identificamos la persona más joven y la persona más vieja de la lista de usuarios.

```
#Muestra de información 5
# Inicializamos variables para la persona más joven y la persona más vieja.
#Estas se utilizarán para mantener un seguimiento de la persona más joven
# y la persona más vieja, respectivamente.

#Al principio, se establecen en None porque aún no hemos encontrado ninguna persona.

personasmasjovencita = None

personamasviejita = None

for person in resultados: #Itera entre los resultados

age = person['dob']['age'] #Busca la edad

city = person['dob']['age'] #Busca la ciudad

if personasmasjovencita is None or age < personasmasjovencita['age']: #Busca la persona mas joven

personasmasjovencita = {'age': age, 'city': city}

if personamasviejita is None or age > personamasviejita['age']: #Busca la ciudad de la persona mas joven

personamasviejita = {'age': age, 'city': city}

#Busca la ciudad de la persona mas joven

personamasviejita = {'age': age, 'city': city}
```

Utilizamos las variables "personasmasjovencita" y "personamasviejita" con valor "none", y luego iteramos a través de los resultados, obteniendo la edad y ciudad de cada. Finalmente, comparamos la edad del usuario actual con las edades de los usuarios más jóvenes y más mayores registrados en nuestra base de datos.

2.8. Presentación de Resultados

¿Qué edad que tenían los usuarios cuando se dieron de alta en la plataforma?

```
#Muestra 1
vEdad1 = rango_etario(edad_registro)[0]
vEdad2 = rango_etario(edad_registro)[1]
vEdad3 = rango_etario(edad_registro)[2]
vEdad4 = rango_etario(edad_registro)[3]

print("Muestra de información 1: ¿Qué edad que tenían los usuarios cuando se dieron de alta en la plataforma?")
print("El", + vEdad1,"% de ususarios se registraron a una edad menor de 20 años.")
print("El", + vEdad2,"% de ususarios se registraron a una edad entre los 21 - 40 años.")
print("El", + vEdad3,"% de ususarios se registraron a una edad entre los 41 - 60 años.")
print("El", + vEdad4,"% de ususarios se registraron a una edad mayor de 60 años.")

Muestra de información 1: ¿Qué edad que tenían los usuarios cuando se dieron de alta en la plataforma?
El 15.0 % de ususarios se registraron a una edad menor de 20 años.
El 36.0 % de ususarios se registraron a una edad entre los 21 - 40 años.
El 34.0 % de ususarios se registraron a una edad entre los 41 - 60 años.
El 15.0 % de ususarios se registraron a una edad entre los 41 - 60 años.
El 15.0 % de ususarios se registraron a una edad mayor de 60 años.
```

¿Cuál es el país con mayor número de usuarios en la plataforma?

```
#Muestra 2
vPais = numUsuarios()[0]
vUsuPais = numUsuarios()[1]
print("Muestra de información 2:¿Cuál es el país con mayor número de usuarios en la plataforma?")
print("El país en donde se encuentra el mayor número de usuarios es:", vPais, "con", vUsuPais, "personas")
```

Muestra de información 2:¿Cuál es el país con mayor número de usuarios en la plataforma? El país en donde se encuentra el mayor número de usuarios es: France con 8 personas

¿Qué tan seguras son las contraseñas que usan los usuarios de la plataforma?

¿En qué zona horaria se conectan más los usuarios de la plataforma?

```
#Muestra 4
vZonHr = Zona_horaria()[0]
vUsuZonHr = Zona_horaria()[1]
print("Muestra de información 4:¿En qué zona horaria se conectan más los usuarios de la plataforma?")
print("La mayor zona horaria se encuentra entre las:",vZonHr, "con",vUsuZonHr,"usuarios")
```

Muestra de información 4:¿En qué zona horaria se conectan más los usuarios de la plataforma? La mayor zona horaria se encuentra entre las: +7:00 con 8 usuarios ¿Qué edad tiene el usuario más joven y el de mayor edad y de qué ciudad son?

```
#Muestra 5
edPerJov = personasmasjovencita['age']
ciuPerJov = personasmasjovencita['city']

edPerMay = personamasviejita['age']
ciuPerMay = personamasviejita['city']

print("Muestra de información 5:¿Qué edad tiene el usuario más joven y el de mayor edad y de qué ciudad son?")
print("La edad de la persona mas joven es: ",edPerJov, "con una edad de: ",ciuPerJov)
print("La edad de la persona mas vieja es: ",edPerMay, "con una edad de: ",ciuPerMay)

Muestra de información 5:¿Qué edad tiene el usuario más joven y el de mayor edad y de qué ciudad son?
La edad de la persona mas joven es: 23 con una edad de: Bor
La edad de la persona mas vieja es: 79 con una edad de: Enterprise
```

Parte 3: Carga

3.1. La parte final consiste en que carguemos la información a una base de datos, y a continuación mostramos una de las formas de almacenar los resultados de nuestro ETL para poder analizar y realizar un seguimiento posterior.

Primero, obtenemos todas las variables necesarias a partir de varias funciones. Después, establecemos una conexión a la base de datos y creamos un cursor para facilitar la interacción. A continuación, definimos la consulta SQL ("InserInfo") que nos permitirá insertar los datos en la tabla "infraestructuras" y ejecutamos la transacción utilizando la función "execute" para llevar a cabo la inserción de datos. Finalmente, confirmamos la transacción mediante "commit", asegurándonos de esta forma que todos los cambios se guarden correctamente en la base de datos.

Esta tabla nos muestra la carga de la información en formato de lista, con ejemplos de pruebas que se hicieron para verificar la conexión y la subida a la base de datos.

1 • SELECT * FROM bdd_infraestructuras.infraestructuras;

